PROJETO INTEGRADOR · DADOS E SEGURANÇA PÚBLICA
FASE 2 · UNIFICAÇÃO, TRATAMENTO, MODELAGEM E ARMAZENAMENTO
RELATÓRIO EXPLICATIVO

dados reais, 2019 a 2024

Do dado bruto ao banco.

Como juntamos registros policiais e declarações de óbito para enxergar o feminicídio por gênero, raça e idade, e o que decidimos no caminho.

EQUIPE

Gustavo Souza Santos · Mateus Bulhões

OUTUBRO DE 2026 | SINESP-VDE · SIM/DATASUS · IBGE · POSTGRESQL NO AIVEN

EM UMA PÁGINA

O que fizemos

Para quem só tem cinco minutos

A Fase 1 escolheu o tema e as fontes. Esta fase transformou isso em uma base de dados de verdade. Baixamos seis planilhas do Ministério da Justiça e seis arquivos anuais de óbitos do DataSUS, algo em torno de 2,6 GB. Filtramos o que interessa, corrigimos os problemas que encontramos, juntamos tudo em um modelo estrela e carregamos no PostgreSQL do Aiven. O resultado cabe em 26 MB e responde, por município e mês, quantas mulheres foram vítimas de cada crime e, para os óbitos, qual era a raça/cor, a idade e o meio da agressão.

13,9mi

linhas lidas nas fontes originais

4,59 mi SINESP + 9,28 mi SIM

256mil

linhas no banco, já agregadas no grão de análise

duas tabelas fato

26MB

espaço ocupado no Aiven, de 1 GB disponível

2,5% do Free Tier

67%

das mulheres mortas por agressão eram negras

SIM, 2019 a 2024

O PROBLEMA

Duas fontes, duas metades

A SINESP sabe o gênero da vítima mas não a raça. O SIM sabe a raça mas não o tipo de crime. Nenhuma delas responde sozinha à pergunta interseccional.

A SAÍDA

Dimensões em comum

Mês, município e sexo existem nas duas. Com essas três chaves conformadas, as fontes ficam lado a lado sem misturar os números.

O CUIDADO

Nada inventado

Cada linha descartada foi contada. Cada arquivo original tem seu SHA-256 guardado dentro do próprio banco. Quem quiser pode refazer tudo com três comandos.

O QUE ENTREGAMOS

Banco, painel e código

Schema **vde** no Aiven, um painel HTML que filtra os dados sem servidor, o repositório com testes e este relatório.

PARTE 1 · ORIGEM

De onde vieram os dados

Três fontes públicas, nenhuma delas feita para conversar com a outra

O pipeline baixa tudo sozinho dos links oficiais. Isso deu mais trabalho do que parece: o portal antigo do Ministério da Justiça saiu do ar no meio do projeto e os arquivos do SIM mudaram de endereço e de formato de um ano para o outro. Os links atuais estão fixados em **etl/config.py**.

FONTE	O QUE TRAZ	FORMATO	TAMANHO E DETALHES
SINESP-VDE Ministério da Justiça	Vítimas por UF, município, mês e tipo de evento, com quebra por sexo. É o registro policial.	Um XLSX por ano, cerca de 765 mil linhas cada	24 MB por arquivo. 31 indicadores, dos quais só 8 interessam ao tema.
SIM DataSUS / OpenDataSUS	Uma linha por Declaração de Óbito, com causa básica (CID-10), sexo, raça/cor, idade e município de ocorrência.	CSV com ponto e vírgula (2019 e 2020) e CSV dentro de ZIP (2021 a 2024)	De 44 MB a 633 MB por ano, 1,3 a 1,8 milhão de óbitos. 2022 e 2023 vieram sem cabeçalho; 2024 é preliminar (DO24OPEN).
IBGE Localidades	Código e nome dos 5.571 municípios.	JSON pela API REST	2,4 MB. É a ponte entre o nome do município (SINESP) e o código (SIM).

Versão original: a prova de qual arquivo usamos

Antes de tocar em qualquer arquivo, o pipeline calcula o SHA-256 dele e grava em **data/raw/manifest.json**. Na carga, esse hash vai para a tabela **meta_carga**, junto com o nome, o tamanho, quantas linhas foram lidas e quantas sobraram após o filtro. Se o Ministério republicar um arquivo, dá para saber. Os brutos ficam fora do git por causa do tamanho; o manifesto fica dentro.

FONTE	ARQUIVO	TAMANHO	LINHAS LIDAS	APÓS FILTRO	SHA-256 (INÍCIO)
SINESP	BancoVDE 2019.xlsx … 2024.xlsx (6 arquivos)	24,2 a 24,4 MB	764.700 a 764.820	406.086 a 406.191	`01d5cefb…` a `87deaea4…`
SIM	Mortalidade_Geral_2019.csv	459,9 MB	1.349.801	3.728	`05acd2eea502`
SIM	Mortalidade_Geral_2020.csv	531,9 MB	1.556.824	3.822	`2fdd9fcc8924`
SIM	Mortalidade_Geral_2021_csv.zip	106,7 MB	1.832.649	3.844	`6a8fe8077cf1`
SIM	Mortalidade_Geral_2022_csv.zip	86,9 MB	1.544.266	3.788	`10b37a98b9c2`
SIM	Mortalidade_Geral_2023_csv.zip	86,9 MB	1.465.610	3.887	`9a14ef4355b7`
SIM	DO24OPEN_csv.zip (preliminar)	98,1 MB	1.532.015	3.622	`13db250c9090`
IBGE	municipios.json	2,4 MB	5.571	5.571	`77bf68d9f5b1`

A lista completa, com os hashes inteiros, está em docs/relatorio_tratamento.md e na tabela vde.meta_carga.

PARTE 2 · PROCESSO

O caminho do dado

Um ETL em Python, três etapas, um módulo para cada uma

Escolhemos Python com pandas porque uma única biblioteca lê XLSX, CSV e JSON, e porque o SIM é grande demais para abrir inteiro na memória: cada ano tem mais de 1,3 milhão de linhas e 80 colunas. A leitura em blocos de 200 mil linhas resolve isso. Cada bloco é filtrado e agregado antes do próximo entrar.

1

Extrair

Baixa as três fontes, extrai os ZIPs do SIM, coloca cabeçalho nos arquivos de 2022 e 2023 e grava o manifesto com o SHA-256 de cada um. Os arquivos oficiais nunca são alterados.

`etl/extract.py` · `etl/padronizar_sim.py`

2

Tratar

Aplica as regras das próximas páginas. Cada passo conta quantas linhas entraram e quantas saíram, e esse rastro vira o relatório de tratamento.

`etl/transform_sinesp.py` · `etl/transform_sim.py` · `etl/dimensoes.py`

3

Carregar

Recria o schema, carrega as 11 tabelas com COPY (o jeito mais rápido do PostgreSQL) e cria as visões analíticas. Tudo em uma transação: se algo falha, o banco volta ao que era.

`etl/load.py` · `sql/01_schema.sql` · `sql/02_views.sql`

O rastro, em números

SINESP-VDE	LINHAS
Lidas nos 6 arquivos	4.588.376
Após manter só os 8 eventos do tema	2.436.806
Repetidas no mesmo arquivo (mantidas, ver DF)	13.743
Nomes de município sem par no IBGE	0
Linhas no fato (mês × município × evento × sexo)	**233.988**
Vítimas somadas (conferência)	968.489

SIM/DATASUS	LINHAS
Declarações de óbito lidas	9.281.165
Após filtro de agressão (X85 a Y09) e sexo feminino	22.691
Com data de óbito inválida	0
Código de município sem par (vai para "não informado" da UF)	1
Linhas no fato (mês × município × raça × idade × meio)	**22.005**
Óbitos somados (conferência)	22.691

Por que agregar antes de carregar? O tema pede contagens e taxas, não pessoas. Guardar uma linha por óbito significaria levar 9 milhões de registros com dados sensíveis para um banco de 1 GB, sem nenhum ganho analítico. Agregando no ETL, 13,9 milhões de linhas viram 256 mil, e nenhuma delas identifica alguém.

Um detalhe de ambiente que vale registrar: o Windows desta máquina bloqueou, via Smart App Control, o Python do ambiente virtual e as DLLs do numpy e do pandas. A solução foi fixar as versões em **requirements.txt** e rodar com o interpretador do uv apontando para os pacotes do **.venv**. O script **scripts/finalizar_entrega.ps1** já faz isso.

O que a SINESP tinha de errado e o que fizemos

Onze decisões, cada uma com um motivo

#	O QUE ENCONTRAMOS	O QUE DECIDIMOS	POR QUÊ
1	Nomes de coluna mudam de um ano para o outro.	Normalizar (minúsculas, sem acento, com sublinhado) e validar as 7 colunas obrigatórias.	O pipeline não quebra com layout novo e falha cedo se faltar campo essencial.
2	A data vem como data, como texto "MM/AAAA" ou separada em ano e mês.	Converter tudo para DATE no dia 01.	Grão mensal único, igual ao do SIM.
3	31 indicadores, a maioria fora do tema (apreensão de drogas, roubo de carga...).	Manter 8 eventos de violência contra a pessoa. A comparação ignora acento e caixa.	Foco no tema e metade do volume.
4	Contagens como texto com separador de milhar ("1.050").	Função **inteiro_br()**: tira o ponto, troca a vírgula, converte para inteiro.	Sem isso, "1.050" vira 1,05.
5	Linhas com total de vítimas maior que zero e sexo em branco.	Total vai para "Não informado".	Não perde vítima e não inventa sexo. No dado real: 0 casos.
6	Soma por sexo diferente do total informado.	Manter a quebra por sexo e contar as ocorrências.	Gênero é o eixo da análise. No dado real: 0 casos.
7	Linhas repetidas. O DF lança uma linha por Região Administrativa, todas como "BRASÍLIA", sem coluna que diferencie.	Remover só a mesma linha repetida em *outro* arquivo. Repetições no mesmo arquivo são mantidas e somadas.	A primeira versão removia tudo e apagava 60% das vítimas do DF (feminicídios de 2019: 32 no bruto, 13 depois). Fora do DF, as repetições têm zero vítimas.
8	Município identificado só pelo nome.	Casar com o IBGE por nome normalizado, mais uma tabela de 11 apelidos (Embu → Embu das Artes, Açu → Assu...).	Gera o código IBGE, que é a chave para cruzar com o SIM.
9	Nome sem par no IBGE ou "não informado".	Vai para a linha "NÃO INFORMADO" da UF e aparece no relatório.	Preserva o total estadual; a lista orienta novos apelidos.
10	Colunas agente, arma, faixa etária e peso.	Descartadas.	Detalham outros indicadores. Nas linhas do nosso escopo estão todas vazias, e o relatório prova isso.
11	Formato largo: uma coluna para feminino, outra para masculino, outra para não informado.	Despivotar para uma linha por sexo.	Sexo vira dimensão, igual no SIM, e as duas fontes ficam comparáveis.

A decisão 7 foi a que mais nos ensinou. Parecia óbvio remover linhas idênticas. Só depois de medir ano a ano (docs/impacto_duplicatas.csv) vimos que a duplicidade era uma característica do DF, não um erro. Regra que vale para 26 estados pode destruir o 27º.

O que o SIM tinha de errado e o que fizemos

Sete decisões para transformar 9 milhões de óbitos em 22 mil linhas úteis

#	O QUE ENCONTRAMOS	O QUE DECIDIMOS	POR QUÊ
1	Cerca de 1,5 milhão de linhas por ano, mais de 80 colunas.	Ler só 6 colunas, em blocos de 200 mil linhas, agregando cada bloco antes do próximo.	Memória constante. O arquivo de 633 MB nunca fica inteiro na RAM.
2	Todas as causas de morte.	Filtrar CAUSABAS entre X85 e Y09 (agressões) por expressão regular, e SEXO feminino ("2" ou "F").	É o recorte da Fase 1. A regex rejeita códigos truncados como "X9".
3	Data de óbito como DDMMAAAA e às vezes sem o zero à esquerda ("1032019").	Ler como texto, completar com zeros e converter.	Sem isso, todo óbito de dia 1 a 9 vira data inválida.
4	Idade codificada: o primeiro dígito diz a unidade (0 minutos, 1 horas, 2 dias, 3 meses, 4 anos, 5 = 100+).	Unidades 0 a 3 valem 0 anos; vazio e 999 viram "ignorada". Agrupar em 9 faixas.	Faixa etária é o terceiro eixo interseccional. Um bug inicial classificava minutos como ignorada.
5	Raça/cor vazia ou fora do domínio.	Mapear para 9 = Ignorada. Criar a flag **negra** = preta + parda.	Critério do IBGE e do FBSP. Ignorados ficam visíveis em vez de sumir.
6	Causa com 4 caracteres (X954).	Agrupar pelo meio da agressão: arma de fogo, objeto cortante, contundente, enforcamento, força corporal, outros.	Dimensão útil e com poucos valores.
7	Código de município com 6 dígitos, sem dígito verificador.	Casar com o código IBGE dividido por 10. Sem par: "NÃO INFORMADO" da UF (2 primeiros dígitos). Sem UF válida: descartar e contar.	Usamos o município de ocorrência, que é o comparável ao registro policial.

Decisões que valem para as duas fontes

D-01 Toda decisão de recorte (anos, eventos, CIDs, apelidos) fica em um arquivo só, **etl/config.py**. Mudar o recorte não exige mexer na lógica.

D-02 Nenhum arquivo original é alterado. Quando um arquivo precisa de ajuste (SIM 2022 e 2023 sem cabeçalho), geramos um novo e guardamos o hash dos dois.

D-03 Linha descartada é linha contada. O relatório de tratamento mostra o antes e o depois de cada etapa.

D-04 Quando o dado está incompleto, ele vai para uma categoria "não informado" ou "ignorada" explícita. Preferimos ver o buraco a fingir que ele não existe.

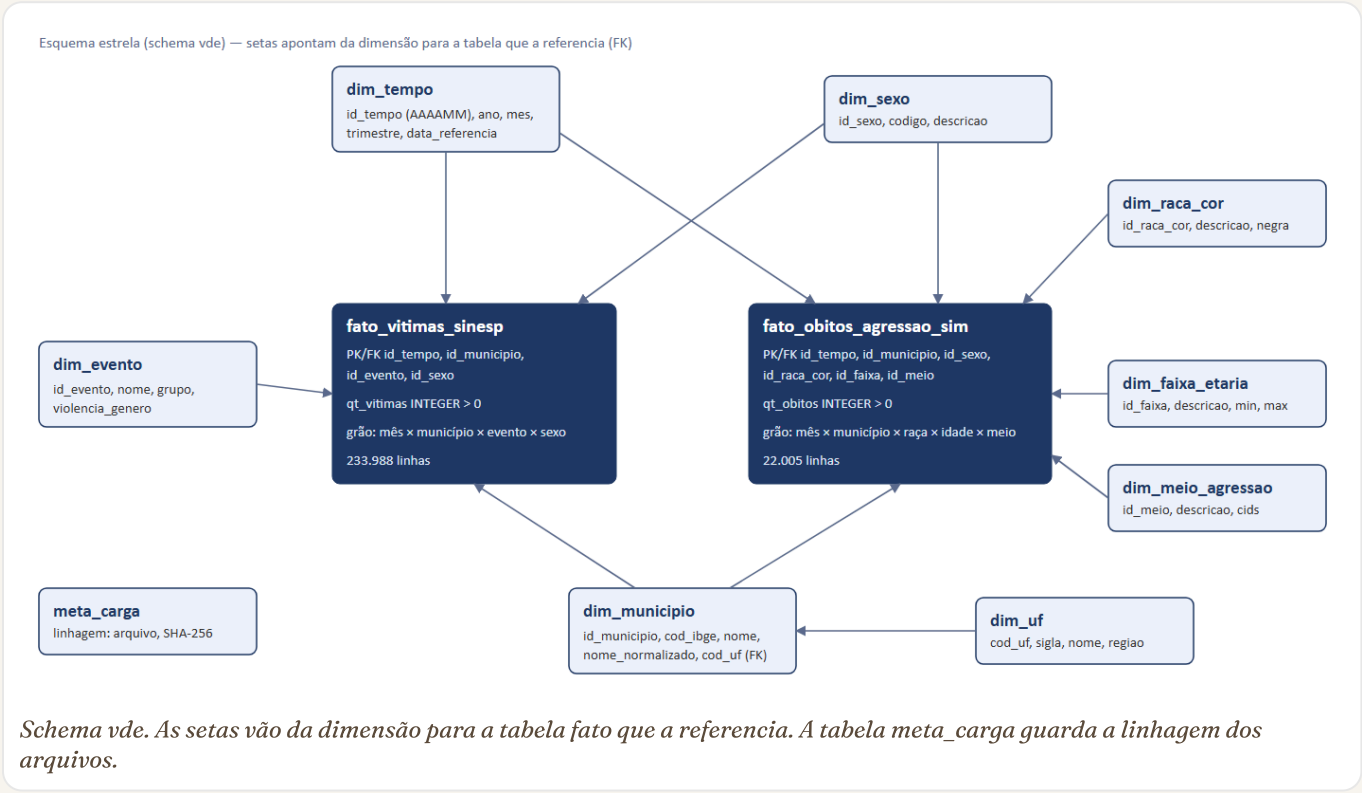
D-05 A carga é idempotente: rodar duas vezes dá o mesmo resultado, porque o schema é recriado e tudo entra em uma transação.

D-06 Os testes usam arquivos sintéticos com os defeitos reais (milhar em texto, duplicata, data sem zero, sexo "F" e "2", município inexistente, UF inválida).

Uma estrela com duas tabelas fato

Por que não forçamos tudo em uma tabela só

A finalidade da base é analítica: KPIs e painéis na Fase 3. O esquema estrela deixa as consultas com poucos *joins* e fáceis de ler. Usamos duas fatos porque as fontes têm grãos e medidas diferentes: a SINESP conta vítimas por evento e sexo, o SIM conta óbitos por raça, idade e meio. Uma tabela única teria colunas vazias pela metade e somas erradas. O que as une são três dimensões conformadas, compartilhadas pelas duas: tempo, município (com UF) e sexo.



Schema vde. As setas vão da dimensão para a tabela fato que a referencia. A tabela meta_carga guarda a linhagem dos arquivos.

Integridade garantida pelo banco

Chave estrangeira em todos os relacionamentos. **CHECK** em mês (1 a 12), ano (2019 a 2024) e quantidades (maiores que zero). **UNIQUE** nos códigos naturais: sigla da UF, código IBGE, data de referência. A chave primária de cada fato é composta pelas suas FKs, então não existe linha duplicada no mesmo grão.

A visão que junta as duas fontes

vw_comparativo_uf_ano coloca, no grão UF × ano, os feminicídios da SINESP (todas as vítimas e só as mulheres) ao lado dos óbitos de mulheres por agressão do SIM e do percentual de mulheres negras. É a tabela que o painel mostra e a que a Fase 3 vai consumir. Há ainda uma visão por gênero e outra por raça/cor, já no formato de dashboard.

PARTE 3 · ARMAZENAMENTO

O que está no banco

Aiven for PostgreSQL 18.6, schema vde, Free Tier de 1 GB

TABELA	CAMPOS (TIPO)	CHAVE	LINHAS	TAMANHO
dim_tempo	id_tempo (INTEGER, AAAAMM), ano, mes, trimestre (SMALLINT), data_referencia (DATE)	PK id_tempo	72	40 KB
dim_uf	cod_uf (SMALLINT), sigla (CHAR 2), nome, regiao (VARCHAR)	PK cod_uf	27	40 KB
dim_municipio	id_municipio (SERIAL), cod_ibge (INTEGER, único), nome, nome_normalizado (VARCHAR), cod_uf (SMALLINT)	PK id_municipio · FK dim_uf	5.598	1.128 KB
dim_sexo	id_sexo (SMALLINT), codigo (CHAR 1), descricao (VARCHAR)	PK id_sexo	3	40 KB
dim_raca_cor	id_raca_cor (SMALLINT), descricao (VARCHAR), negra (BOOLEAN)	PK id_raca_cor	6	24 KB
dim_faixa_etaria	id_faixa (SMALLINT), descricao (VARCHAR), idade_min, idade_max (SMALLINT)	PK id_faixa	9	40 KB
dim_evento	id_evento (SMALLINT), nome, grupo (VARCHAR), violencia_genero (BOOLEAN)	PK id_evento	8	40 KB
dim_meio_agressao	id_meio (SMALLINT), descricao, cids (VARCHAR)	PK id_meio	6	40 KB
fato_vitimas_sinesp	id_tempo, id_municipio, id_evento, id_sexo (FKs), qt_vitimas (INTEGER > 0)	PK composta (4 FKs)	233.988	21.392 KB
fato_obitos_agressao_sim	id_tempo, id_municipio, id_sexo, id_raca_cor, id_faixa, id_meio (FKs), qt_obitos (INTEGER > 0)	PK composta (6 FKs)	22.005	2.592 KB
meta_carga	fonte, arquivo, sha256 (CHAR 64), tamanho_bytes, linhas_lidas, linhas_apos_filtro (BIGINT), arquivo_origem, sha256_origem, executado_em (TIMESTAMPTZ)	PK id_carga	13	32 KB

Contagens e tamanhos lidos do Aiven pelo sql/03_verificacao.sql em 10/10/2026. Total do schema: 26,02 MB (2,54% do plano).

11
tabelas no schema vde
8 dimensões, 2 fatos, 1 linhagem

11
chaves estrangeiras conferidas
information_schema

3
visões analíticas prontas para a Fase 3
sql/02_views.sql

25min
para recarregar tudo do zero
6 XLSX + 9 mi de óbitos

Amostra da visão interseccional, 2024

UF	FEMINICÍDIOS (SINESP)	VÍTIMA MULHER	VÍTIMAS LETAIS MULHERES	ÓBITOS MULHERES (SIM)	MULHERES NEGRAS	% NEGRAS
BA	110	110	403	405	356	87,9%
SP	253	251	447	348	140	40,2%
PE	76	76	264	273	221	81,0%
CE	41	41	312	269	251	93,3%
MG	169	169	358	266	178	66,9%
RS	73	73	205	202	39	19,3%

Como sabemos que está certo

Testes, conferência de totais e comparação com quem publica esses números

Testes automatizados

Nove testes com pytest. O script **tests/gerar_fixtures.py** cria arquivos no formato real das fontes com os defeitos típicos, e cada teste confere uma regra: milhar em texto vira inteiro, a duplicata certa é removida, a data sem zero é lida, o sexo "F" e "2" são o mesmo, o município inexistente cai em "não informado", a UF inválida é descartada e contada. Os totais de vítimas e óbitos têm de bater antes e depois do tratamento.

Revisão adversarial

Antes de fechar, pedimos a uma segunda leitura que tentasse quebrar o pipeline. Ela achou cinco problemas, todos corrigidos: as linhas do DF (decisão 7), a idade em minutos, o filtro de CID sem regex, a linhagem do ZIP original do SIM e uma consulta de tamanho que contava índices duas vezes.

Conferência por ano

ANO	FEMINICÍDIOS (SINESP)	VÍTIMA MULHER	ÓBITOS MULHERES (SIM)	% NEGRAS
2019	1.331	1.322	3.728	66,0%
2020	1.346	1.335	3.822	67,4%
2021	1.366	1.358	3.844	67,4%
2022	1.456	1.446	3.788	66,3%
2023	1.478	1.468	3.887	68,1%
2024	1.501	1.494	3.622	67,5%

Contra as publicações oficiais

O Anuário Brasileiro de Segurança Pública (FBSP) registra 1.492 feminicídios em 2024 na edição 2025, revisados para 1.504 na edição 2026. Nossa base, a partir da mesma SINESP, chegou a 1.501. O Atlas da Violência 2025 (Ipea e FBSP), que usa o mesmo SIM, aponta 3.903 mulheres assassinadas em 2023, 68,2% delas negras. Aqui: 3.887 e 68,1%. A diferença de 16 óbitos vem do recorte: o Atlas soma também as mortes por intervenção legal (CID Y35 e Y36), que este projeto não inclui porque não são agressão no sentido da nossa pergunta.

O que ainda não está perfeito

L-01 **Feminicídio com vítima não feminina.** A SINESP traz de 3 a 9 vítimas do sexo masculino por ano nesse evento, mais 1 a 4 sem sexo. Provável erro de registro na origem. Mantivemos como veio e a visão oferece as duas medidas.

L-02 **Estupro só por UF.** Estupro e estupro de vulnerável não têm município na SINESP: 100% ficam em "não informado". Mapas desses eventos devem usar UF.

L-03 **SIM 2024 é preliminar.** O arquivo DO24OPEN tem cerca de 7% menos óbitos que 2023 em todos os meses. O Ministério da Saúde ainda pode revisar.

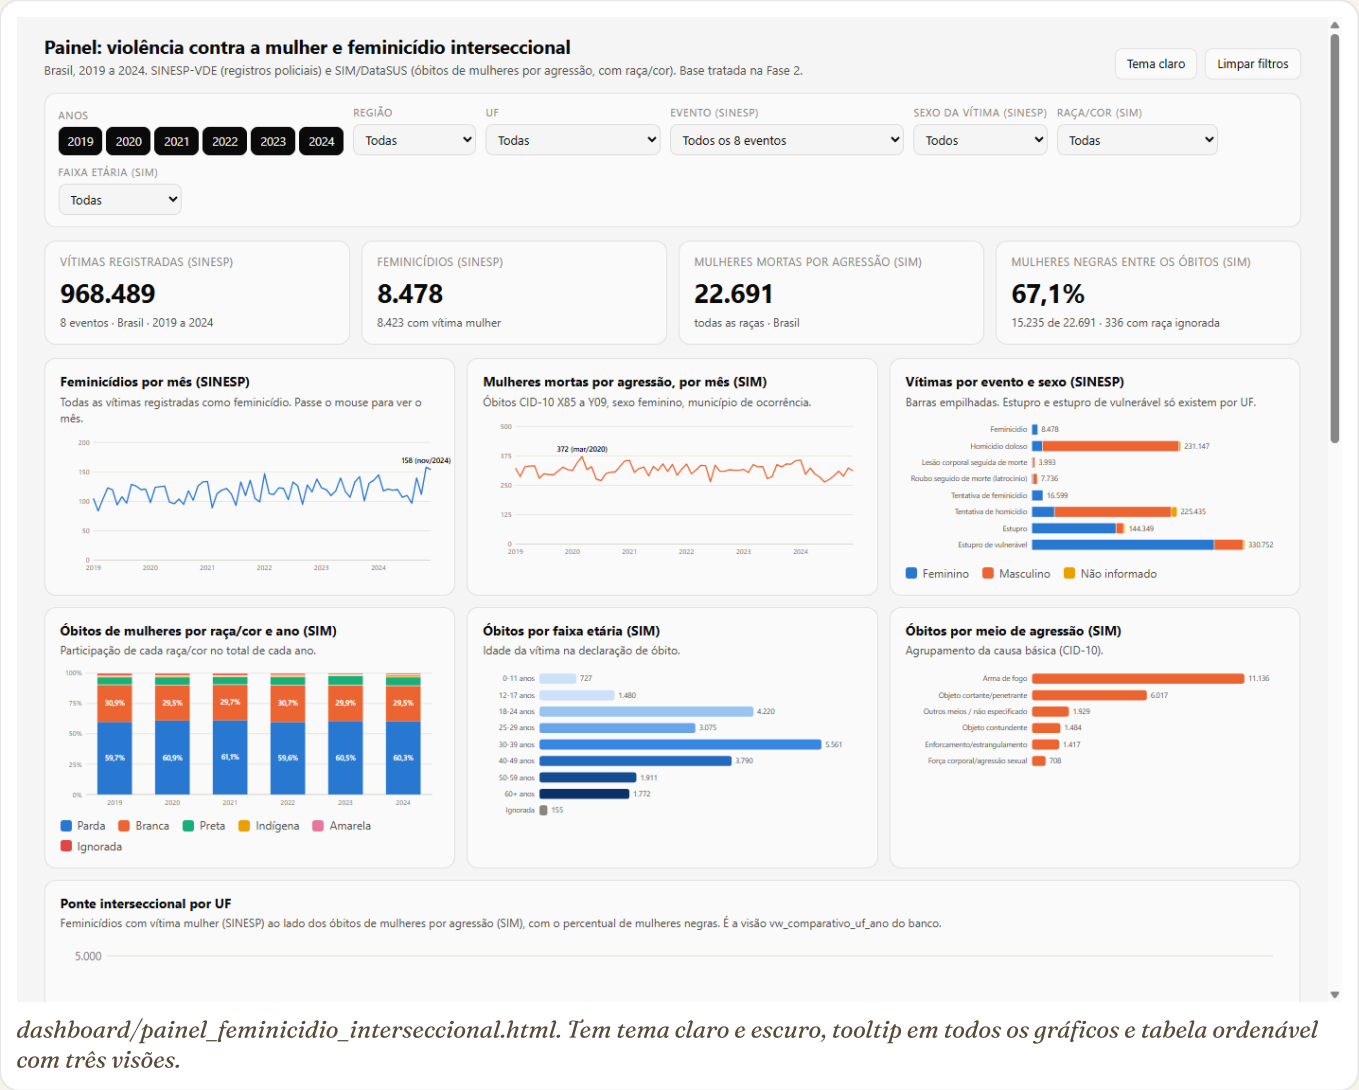
L-04 **Raça/cor ignorada.** 1,5% dos óbitos (336 de 22.691) não têm raça/cor. Eles ficam no denominador, então o percentual de mulheres negras é um pouco conservador.

PARTE 5 · USO

O painel

Um arquivo HTML que abre em qualquer navegador, sem servidor e sem internet

Para ninguém precisar escrever SQL para olhar os dados, geramos um painel a partir dos mesmos CSVs tratados que foram para o banco. Os números batem um a um com as tabelas fato. Os filtros de ano, região, UF, evento, sexo, raça/cor e faixa etária valem para todos os gráficos, os cartões e a tabela ao mesmo tempo. Qualquer recorte pode ser baixado em CSV. O arquivo tem 1 MB e os dados vão embutidos nele, já agregados por mês e UF.



dashboard/painel_feminicidio_interseccional.html. Tem tema claro e escuro, tooltip em todos os gráficos e tabela ordenável com três visões.

O que dá para responder

Quantos feminicídios houve em cada mês de cada estado. Qual a participação das mulheres negras entre as mortas por agressão em cada UF (de 19% no RS a 97% no AP). Qual o meio de agressão mais comum (arma de fogo, metade dos casos) e em que faixa etária se concentram as mortes (30 a 39 anos). Quais municípios registram mais feminicídios.

Como regenerar

Depois de rodar o pipeline, um comando reconstrói o painel com os dados novos: **python dashboard/gerar_painel.py**. O layout fica em **dashboard/template.html**; o script só injeta os dados. Cores foram validadas para daltonismo e todo gráfico com mais de uma série tem legenda e rótulo direto.

PARTE 5 · REPRODUÇÃO

Para refazer tudo

Três comandos e cerca de meia hora

```
pip install -r requirements.txt
cp .env.example .env            # colar a Service URI do Aiven em DATABASE_URL
python run_pipeline.py          # baixa (~2,6 GB), trata, carrega e gera docs/relatorio_tratamento
python -m scripts.verificar_banco   # roda sql/03_verificacao.sql e grava docs/verificacao_banco.m
python -m pytest -q tests       # 9 testes das regras de tratamento
python dashboard/gerar_painel.py    # reconstrói o painel HTML
```

Opções úteis: **--sem-download** usa o que já está em data/raw e **--sem-banco** só trata e gera os CSVs, sem carregar. No Windows com Smart App Control, use **scripts/finalizar_entrega.ps1**, que já contorna o bloqueio do Python do .venv.

Onde está cada coisa

```
run_pipeline.py               orquestra extração → tratamento → carga → relatório
etl/
  config.py                   TODAS as decisões de recorte (anos, eventos, CIDs, apelidos, URLs)
  extract.py                  download das três fontes, ZIPs do SIM, manifesto SHA-256
  padronizar_sim.py           cabeçalho para os CSVs de 2022 e 2023
  dimensoes.py                dimensões estáticas + municípios via API do IBGE
  transform_sinesp.py         as 11 decisões da SINESP
  transform_sim.py            as 7 decisões do SIM, em blocos de 200 mil linhas
  load.py                     DDL + COPY em uma transação
  utils.py                    normalização de texto e números no formato brasileiro
sql/
  01_schema.sql               modelo estrela (DDL, FKs, CHECKs)
  02_views.sql                três visões analíticas para a Fase 3
  03_verificacao.sql          contagens, tamanho, tipos, FKs e linhagem
tests/                        fixtures sintéticas + 9 testes (pytest)
dashboard/                    gerar_painel.py, template.html e o painel gerado
data/raw/                     originais (fora do git) + manifest.json (no git)
data/processed/               CSVs tratados, um por tabela
docs/relatorio_tratamento.md  rastro de cada execução, com os números reais
docs/verificacao_banco.md     saída da verificação rodada no Aiven
docs/relatorio/               este documento
```

O que fica para a Fase 3. O banco e as visões estão prontos para KPIs e dashboards. Dois pontos pedem atenção: calcular taxas por 100 mil mulheres exige a população do IBGE por município e ano, que ainda não está no modelo; e o SIM de 2024 deve ser recarregado quando a versão definitiva sair, o que é só rodar o pipeline de novo.

EQUIPE

Gustavo Souza Santos · Mateus Bulhões

REPOSITÓRIO

github.com/buga2023/fase2-etl-violencia-genero